Nombre del proyecto

Análisis comparativo de algoritmos

Profesor	Materia	Fecha de Inicio	Fecha de Finalización
ALEXANDRA JACQUELINE ARCINIEGAS CORAL	PROYECTO INTEGRADOR EN INTELIGENCIA ARTIFICIAL	30/03/2026	04/04/2026

Resumen del Proyecto

Análisis comparativo de algoritmos

Responsables del proyecto

Nombre	Rol	Tareas
JAVIER ALEJANDRO VEGA MOLINA	ESTUDIANTE	TODO
MARIO ALBERTO SANCHEZ RAMIREZ	ESTUDIANTE	TODO

Análisis comparativo de algoritmos

1. Fundamentación Teórica de los Algoritmos

En el contexto del procesamiento de secuencias de video en tiempo real para entornos de seguridad, el estado del arte ofrece diversas aproximaciones arquitectónicas. Para este análisis, se evalúan cinco paradigmas algorítmicos.

1.1 Redes Neuronales Convolucionales (CNN) - Familia YOLO

YOLOv8 representa una arquitectura One-Stage que optimiza la velocidad de inferencia al dividir la imagen en una cuadrícula y predecir, de manera concurrente, las cajas delimitadoras y las probabilidades de clase (Jocher, Chaurasia & Qiu, 2023). Esta técnica ha demostrado ser altamente efectiva en la detección de objetos críticos, como armamento, en entornos de videovigilancia (Gupta, Kaur & Kumar, 2025).

1.2 Estimación de Pose Topológica (MediaPipe)

Este marco de trabajo utiliza redes neuronales convolucionales de arquitectura ligera para inferir la topología 3D del cuerpo humano a partir de representaciones 2D. El pipeline orquesta el modelo subyacente (BlazePose) para extraer keypoints articulares con alta fidelidad y baja latencia computacional (Lugaresi et al., 2019; Bazarevsky et al., 2020).

1.3 Vision Transformers (ViT):

Los ViT adaptan los mecanismos de auto-atención (comunes en el procesamiento de lenguaje natural) a la visión artificial. Al dividir la imagen en parches (patches) y analizar las relaciones globales espaciales sin depender de convoluciones tradicionales, logran una comprensión contextual superior del entorno (Dosovitskiy et al., 2020).

1.4 Máquinas de Vectores de Soporte (SVM) + Histograma de Gradientes Orientados (HOG)

Un enfoque algorítmico clásico que consta de una etapa de extracción manual de características morfológicas (HOG) seguida de un clasificador lineal (SVM) que busca el hiperplano óptimo para la separación de clases. Históricamente, este ha sido el estándar pre-Deep Learning para la detección humana en sistemas de seguridad (Alblooshi & Al-Ahmad, 2025).

1.5 Bosques Aleatorios (Random Forest)

Un método de aprendizaje supervisado basado en el ensamble de múltiples árboles de decisión. En el dominio de la visión por computadora y la videovigilancia convencional (Alblooshi & Al-Ahmad, 2025), suele emplearse no sobre los píxeles crudos, sino como un clasificador secundario que procesa datos tabulares o características geométricas previamente extraídas.

2. Criterios de Comparación y Metodología

Para determinar la idoneidad técnica de los algoritmos en el marco del proyecto de disuasión de asaltos, se establecen los siguientes criterios métricos, priorizando el procesamiento local (Edge Computing) definido por el National Institute of Standards and Technology (2025):

1. **Requerimientos de Datos:** Volumen y granularidad de las anotaciones necesarias para el entrenamiento y convergencia del modelo.
2. **Precisión y Robustez:** Sensibilidad del modelo para maximizar la detección verdadera y, críticamente, minimizar la tasa de falsos positivos en entornos dinámicos.
3. **Eficiencia en el Borde (Edge):** Viabilidad operativa sin dependencia de infraestructura en la nube (NIST, 2025).
4. **Complejidad Computacional Asintótica:** Demanda de recursos de procesamiento (FLOPs) y memoria transaccional.
5. **Aplicabilidad Industrial:** Casos de uso típicos comprobados en la literatura reciente (Alblooshi & Al-Ahmad, 2025).

3. Matriz Comparativa Teórica

Técnica	1. Requerimientos de Datos	2. Precisión y Robustez	3. Eficiencia en el Borde (Edge)	4. Complejidad Computacional	5. Aplicabilidad Industrial
YOLOv8 (CNN)	Altos: Extensos corpus de imágenes anotadas con cajas delimitadoras.	Alta precisión en armamento; sensible a oclusiones y problemas de escala.	Alta: Variantes ligeras (Nano) optimizadas para NPUs locales (Jocher et al., 2023).	$O(N \cdot K^2 \cdot C_{in} \cdot C_{out})$ (Lineal espacial).	Detección de amenazas en videovigilancia y prevención de crímenes.
MediaPipe (Pose)	Bajos: Utiliza pesos pre-entrenados; requiere programar heurística espacial.	Inmune al ruido visual; decae en aglomeraciones o oclusión total.	Muy Alta: Latencia mínima operando nativamente en CPU móvil (Lugaresi et al., 2019; Bazarevsky et al., 2020).	$O(K^2 \cdot C_{in} + C_{in} \cdot C_{out})$ (Convolución separable).	Seguimiento biométrico, análisis gestual e interfaces humano-máquina.
Vision Transformers	Muy Altos: Regímenes masivos a escala industrial (ej. JFT-300M).	Máxima precisión teórica al analizar contexto global (Dosovitskiy et al., 2020).	Nula/Inviable: Prohibitiva por restricciones térmicas y de memoria compartida.	$O(P^2 \cdot D)$ (Cuadrática por atención global).	Análisis biomédico, satelital y conducción autónoma pesada.
SVM + HOG	Medios: Datasets balanceados y pre-procesados morfológicamente.	Baja robustez; alta tasa de falsos positivos en entornos dinámicos no controlados.	Alta: Viable en microcontroladores sin aceleración vectorial.	Dependiente del vector; polinomial de bajo grado.	Sistemas heredados, detección estática de peatones.
Random Forest	Bajos: Datos estructurados tabulares (coordenadas).	Alta resistencia al overfitting; incapaz de leer tensores de imágenes crudos.	Alta: Ejecución instantánea de árboles de decisión condicionales.	$O(M \cdot logN)$ (Logarítmica/Muy baja).	Clasificación secundaria, evaluación de reglas lógicas.

4. Evaluación Experimental en Literatura de Referencia

El análisis de rendimiento y viabilidad para hardware de borde revela discrepancias significativas entre los modelos:

4.1 YOLOv8

La literatura demuestra que YOLOv8 es una arquitectura de estado del arte altamente efectiva para la prevención de crímenes. Gupta, Kaur y Kumar (2025) evidencian en su

investigación que el modelo logra tasas de precisión excepcionalmente robustas en la detección de armamento. Además, la arquitectura algorítmica de sus variantes ligeras (YOLOv8n) está diseñada nativamente para permitir altas velocidades de inferencia, viabilizando su uso en sistemas de seguridad (Jocher et al., 2023).

4.2 MediaPipe Pose y BlazePose

Para la detección de posturas en tiempo real, se requiere desacoplar el framework del modelo matemático. Por un lado, Bazarevsky et al. (2020) demuestran que su arquitectura BlazePose tiene la capacidad de rastrear 33 keypoints articulares a velocidades superiores a 30 FPS procesando exclusivamente en CPUs de arquitectura móvil. Por otro lado, la implementación de este modelo dentro del ecosistema MediaPipe permite orquestar estos cálculos con una latencia mínima, ideal para el borde (Lugaresi et al., 2019).

4.3 ViT (Base)

Dosovitskiy et al. (2020) revolucionaron la visión artificial demostrando que los mecanismos de auto-atención pueden superar a las redes convolucionales en precisión global. Sin embargo, su propia investigación detalla que estos modelos requieren capacidades de cómputo masivas (clústeres de TPUs) y enormes conjuntos de datos para su preentrenamiento. Debido a la complejidad computacional cuadrática de la atención global, la literatura de despliegue industrial reconoce que los ViT convencionales son inaplicables para inferencia en tiempo real en dispositivos Edge con restricciones de memoria y energía.

4.4 Clasificadores Tradicionales (SVM)

En el análisis histórico de los sistemas de videovigilancia, las revisiones sistemáticas evidencian que los métodos tradicionales basados en extracción manual de características (como SVM) experimentan caídas inaceptables en la métrica de recall y precisión al enfrentarse a variables de entornos no controlados (como cambios de iluminación o perspectivas), justificando su reemplazo por redes neuronales profundas (Alblooshi & Al-Ahmad, 2025).

5. Discusión Técnica

El desafío central del sistema de monitoreo radica en la dicotomía entre la precisión de detección y la latencia operativa bajo restricciones de hardware local (NIST, 2025). Los modelos del estado del arte, como los Vision Transformers, ofrecen la máxima precisión teórica en pruebas de laboratorio (Dosovitskiy et al., 2020), pero su despliegue fractura el requerimiento fundamental de operar independientemente de la nube. Por el contrario, los enfoques heurísticos clásicos generan un volumen de falsas alarmas que erosionan la confianza del usuario final (Alblooshi & Al-Ahmad, 2025). En consecuencia, la convergencia algorítmica emerge como la única frontera técnica viable: integrar la eficiencia de inferencia semántica de modelos topológicos ligeros (Bazarevsky et al., 2020) con CNNs altamente optimizadas, equilibrando así la velocidad operativa y la viabilidad comercial (Gupta, Kaur & Kumar, 2025).

6. Selección y Justificación Arquitectónica

A partir del análisis expuesto, se determina que la arquitectura óptima para este proyecto es un pipeline híbrido que integra estimación topológica (MediaPipe/BlazePose) y detección convolucional (YOLOv8). La justificación primordial de esta convergencia obedece a que la acción disuasiva del sistema requiere un mecanismo de activación (trigger) conductual inequívoco. En este sentido, la utilización del ecosistema MediaPipe para ejecutar el modelo BlazePose permite identificar la geometría exacta de la postura de "manos arriba", mitigando drásticamente los falsos positivos que las redes convolucionales estándar suelen generar al confundir visualmente armas con objetos inertes cotidianos. Esta fase inicial se sustenta en algoritmos diseñados explícitamente para la percepción estructural con latencia ultrabaja en el borde (Lugaresi et al., 2019; Bazarevsky et al., 2020).

De manera complementaria y concurrente, este núcleo topológico opera en paralelo con YOLOv8, cuya función es actuar como una variable de validación secundaria orientada a la detección de armamento. La integración algorítmica de este modelo convolucional consolida la fiabilidad general del sistema, un enfoque multiobjeto que es respaldado ampliamente por la literatura reciente, la cual demuestra la superioridad táctica de esta arquitectura en sistemas de prevención de crímenes en tiempo real y detección de amenazas balísticas (Gupta, Kaur & Kumar, 2025).

7. Análisis de Complejidad Computacional

La viabilidad del despliegue en hardware local se sustenta en el análisis asintótico de los algoritmos seleccionados en contraste con las alternativas descartadas:

7.1 Vision Transformers (Descartado)

La complejidad computacional está dominada por la auto-atención global, escalando de forma cuadrática respecto al número de parches de la imagen: $O(P^2 \cdot D)$, donde P representa la cantidad de parches y D la dimensionalidad. Esta complejidad cuadrática satura la memoria caché de los dispositivos IoT.

7.2 CNNs Convencionales (YOLOv8)

Operan con una complejidad lineal respecto a la resolución espacial: $O(N \cdot K^2 \cdot C_{in} \cdot C_{out})$, donde N es el tamaño del mapa de características de salida, K es el tamaño del kernel, y C representa los canales de entrada y salida. Esta linealidad permite aplicar cuantización agresiva (FP16/INT8) soportada por NPUs modernas (Jocher et al., 2023).

7.3 MediaPipe (BlazePose)

Logra su eficiencia extrema al reemplazar las convoluciones estándar por convoluciones separables en profundidad (Depthwise Separable Convolutions), reduciendo la complejidad multiplicativa drásticamente de $O(K^2 * C_{in} * C_{out})$ hacia $O(K^2 * C_{in} + C_{in} * C_{out})$ (Howard et al., 2017; Bazarevsky et al., 2020).

Referencias

Alblooshi, A., & Al-Ahmad, H. (2025). AI-Based Weapon Detection for Security Surveillance: Recent Research Advances (2016-2025). Electronics, 14(23), 4609. https://doi.org/10.3390/electronics14234609

Bazarevsky, V., Grishchenko, I., Raveendran, K., Zhu, T., Zhang, F., & Grundmann, M. (2020). BlazePose: On-device Real-time Body Pose tracking. arXiv preprint arXiv:2006.10204. https://arxiv.org/abs/2006.10204

Dosovitskiy, A., Beyer, L., Kolesnikov, A., Weissenborn, D., Zhai, X., Unterthiner, T., ... & Houlsby, N. (2020). An image is worth 16x16 words: Transformers for image recognition at scale. arXiv preprint arXiv:2010.11929. https://arxiv.org/abs/2010.11929

Gupta, R., Kaur, A., & Kumar, S. (2025). Weapon detection with FMR-CNN and YOLOv8 for enhanced crime prevention and security. Scientific Reports, 15, 26766. https://doi.org/10.1038/s41598-025-07782-0

Howard, A. G., Zhu, M., Chen, B., Kalenichenko, D., Wang, W., Weyand, T., Andreetto, M., & Adam, H. (2017). MobileNets: Efficient Convolutional Neural Networks for Mobile Vision Applications. arXiv preprint arXiv:1704.04861. https://arxiv.org/abs/1704.04861

Jocher, G., Chaurasia, A., & Qiu, J. (2023). Ultralytics YOLO (Version 8.0.0) [Software de computadora]. GitHub. https://github.com/ultralytics/ultralytics

Lugaresi, C., Tang, J., Nash, H., McClanahan, C., Uboweja, E., Hays, M., ... & Grundmann, M. (2019). MediaPipe: A Framework for Building Perception Pipelines. arXiv preprint arXiv:1906.08172. https://arxiv.org/abs/1906.08172

National Institute of Standards and Technology. (2025). Edge Computing: Paradigm for Proximity Data Processing (NIST Special Publication). U.S. Department of Commerce.