Nombre del proyecto

Presentación: Evaluación y optimización del modelo

Profesor	Materia	Fecha de Inicio	Fecha de Finalización
ALEXANDRA JACQUELINE ARCINIEGAS CORAL	PROYECTO INTEGRADOR EN INTELIGENCIA ARTIFICIAL	20/04/2026	24/04/2026

Resumen del Proyecto

Presentación: Evaluación y optimización del modelo

Responsables del proyecto

Nombre	Rol	Tareas
JAVIER ALEJANDRO VEGA MOLINA	ESTUDIANTE	TODO
MARIO ALBERTO SANCHEZ RAMIREZ	ESTUDIANTE	TODO

Presentación: Evaluación y optimización del modelo

Proyecto: Sistema de Seguridad Inteligente “Manos Arriba”

1. Definición del Caso de Estudio

1.1 Problema

El objetivo es desarrollar un sistema de visión artificial para la detección del gesto "Manos Arriba", que funcione como un disparador de alerta silencioso en entornos de videovigilancia. La detección debe ser robusta frente a variaciones de resolución de entrada, umbral de confianza y condiciones ambientales como la iluminación (Wang et al., 2025).

1.2 Modelo Seleccionado: YOLO11n-pose

Se emplea el modelo YOLO11n-pose (Ultralytics, 2024), cuya selección se justifica, en primer lugar, por su arquitectura "Nano". Al ser la versión más ligera de la familia YOLO11, resulta crítica para aplicaciones de videovigilancia que requieren procesamiento en tiempo real o en dispositivos de borde (*edge computing*) con recursos limitados (Jocher et al., 2024).

Asimismo, el modelo destaca por su capacidad de Estimación de Pose Humana (HPE), ya que extrae 17 *keypoints* anatómicos basados en el estándar COCO (Lin et al., 2014). Esta característica proporciona la información esencial para implementar una "capa lógica" encargada de evaluar la posición de las muñecas.

Finalmente, la elección se fundamenta en su pre-entrenamiento robusto. Al haber sido entrenado con conjuntos de datos masivos, el modelo cuenta con una excelente capacidad de generalización para operar en distintos escenarios (Lin et al., 2014).

1.3 Métricas Clave

- **Confianza Media (mAP proxy):** Confianza promedio de los keypoints por persona detectada. Refleja la certeza del modelo sobre la localización de las articulaciones.
- **Latencia (ms):** Tiempo de inferencia del modelo, indicador clave para la viabilidad en tiempo real.

1.4 Variables y Parámetros Evaluados

Se seleccionaron los siguientes factores por su impacto directo en la precisión, velocidad y robustez del sistema en entornos reales (Jocher et al., 2024):

Variable / Parámetro	Rango Evaluado	Justificación Técnica
Input Size	320, 480, 640, 800, 960 px	Determina la resolución de entrada. Afecta la cantidad de información espacial y el costo computacional.

Variable / Parámetro	Rango Evaluado	Justificación Técnica
Conf Threshold	0.25, 0.35, 0.45, 0.50, 0.55, 0.65, 0.75	Filtra detecciones de keypoints con baja probabilidad. Controla el balance entre falsos positivos y falsos negativos.
Categoría (Escena)	Asalto / Act. Cotidiana	Evalúa si el rendimiento del modelo está sesgado por el tipo de escenario.
Iluminación	Normal / Baja	Evalúa la robustez del modelo ante condiciones adversas de poca luz.

2. Diseño y Ejecución de Experimentos

Para el diseño experimental, se implementó una búsqueda exhaustiva en cuadrícula (*Grid Search*) sobre un conjunto de 13 imágenes. El espacio de búsqueda contempló la evaluación sistemática de 7 umbrales de confianza y 5 resoluciones de entrada, generando 35 combinaciones por cada imagen. Este procedimiento metodológico resultó en la ejecución de un total de 455 experimentos. El objetivo principal de este diseño fue registrar y analizar el impacto, tanto aislado como en conjunto, de cada variable e hiperparámetro evaluado, lo cual permitió identificar empíricamente la configuración más robusta y óptima para este caso de uso específico en videovigilancia de seguridad.

3. Análisis de Resultados Experimentales

3.1 Análisis de Sensibilidad Individual (Partial Dependence Plots)

Input Size: Se identifica un punto de saturación en 640px. Por debajo de 480px, la degradación del rendimiento es severa debido a la pérdida de resolución espacial. Por encima de 640px, la ganancia de precisión es marginal (Jocher et al., 2024).

Conf Threshold: Muestra un rango óptimo de operación entre 0.45 y 0.55. Valores muy altos (0.75) pueden causar omisiones críticas en escenarios de asalto, mientras que valores bajos (<0.35) introducen ruido, validando la necesidad de un umbral balanceado (Cao et al., 2019).

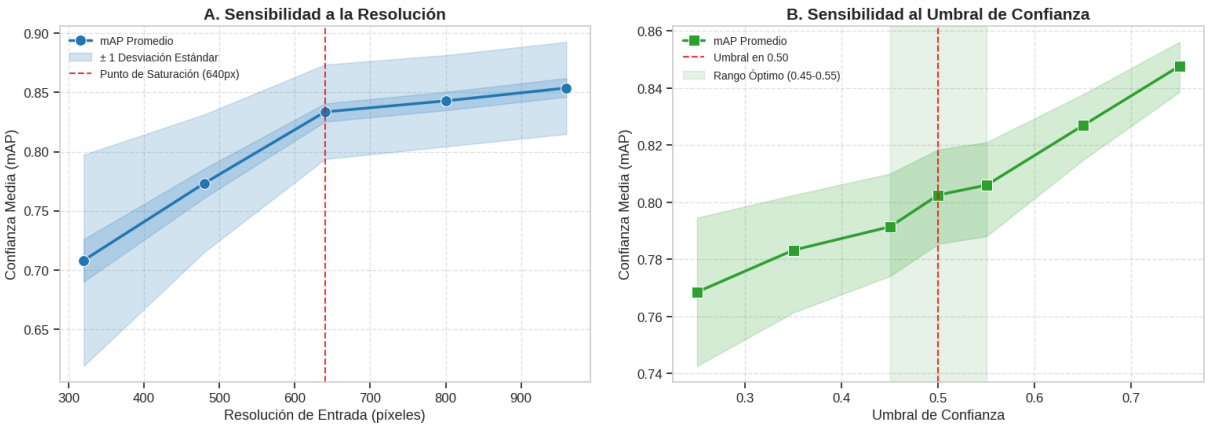

Figura 1 Curvas de sensibilidad para resolución y umbral de confianza.

3.2 Ranking de Importancia de parámetros (Random Forest)

Se construyó el ranking mediante un modelo Random Forest Regressor (Jocher et al., 2024), obteniendo los siguientes resultados:

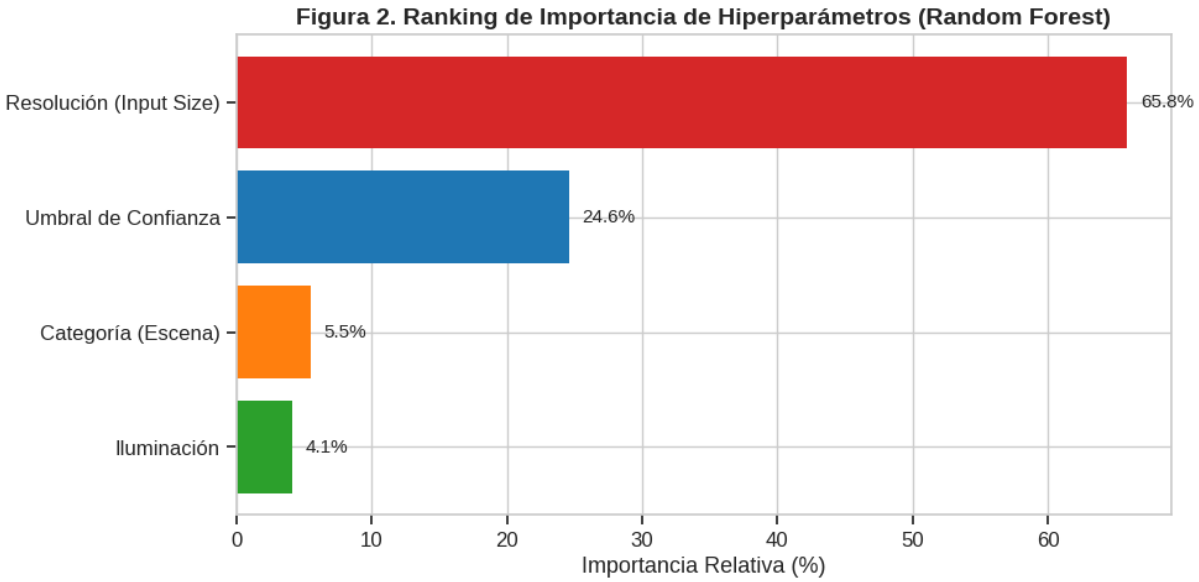

Figura 2 Ranking de importancia de variables y parámetros.

La resolución de entrada es, con mucha diferencia, el factor con mayor influencia, determinando la capacidad del modelo para generalizar. El hecho de que las variables contextuales tengan un impacto marginal (<10%) es un indicador positivo de la robustez del modelo base.

3.3 Análisis de Interacciones (Efectos de Interacción)

En el análisis de interacciones se identificó una sinergia donde la combinación de 640px de *Input Size* con 0.50 de *Conf Threshold* maximiza la robustez, permitiendo una detección estable. Por el contrario, se detectó un conflicto crítico en la configuración de 320px y 0.75 de *Threshold*, donde la baja resolución impide al modelo alcanzar la certidumbre exigida, resultando en el colapso de la detección.

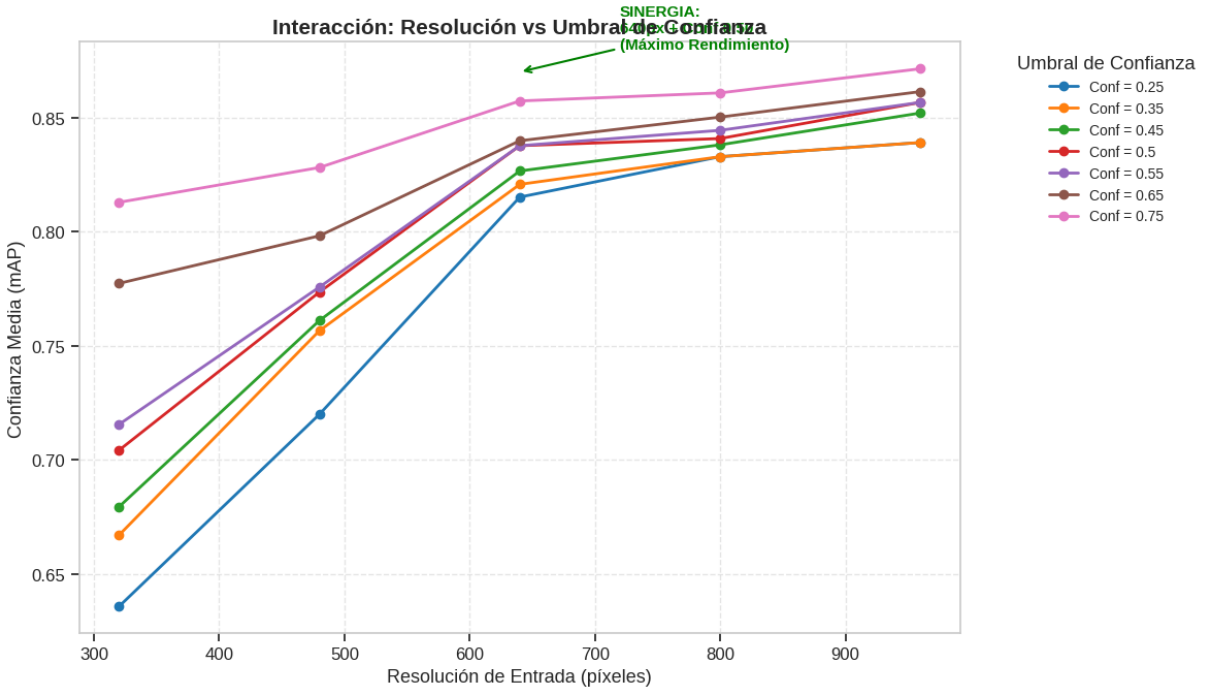

Figura 3 Gráfico de interacción entre resolución y umbral de confianza.

3.4 Detección y Mitigación de Sesgo

Sesgo por Categoría: No se detectó un sesgo significativo (<5% de diferencia), lo que indica una excelente generalización del modelo.

Robustez ante Iluminación: La diferencia de rendimiento entre condiciones de iluminación normal y baja es mínima, demostrando una alta robustez del modelo base. Para escenarios de oscuridad extrema, se recomienda actuar sobre la infraestructura de iluminación en lugar de forzar los hiperparámetros.

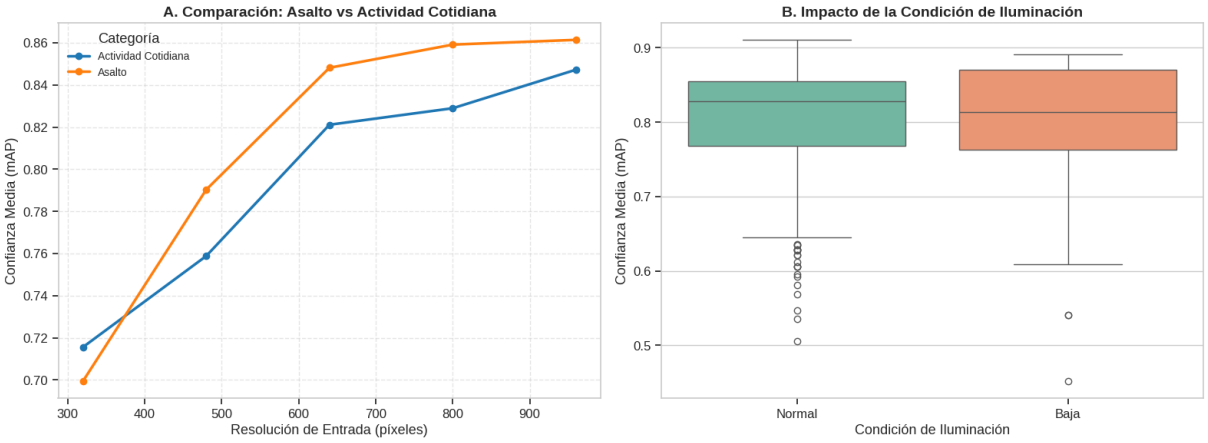

Figura 4 Análisis de sesgo y robustez del modelo.

4. Interpretación y Toma de Decisiones

4.1 Hiperparámetros Críticos

- Input Size = 640 px (Factor no negociable).
- Conf Threshold = 0.50 (Balance óptimo).

4.2 Reducción del Espacio de Búsqueda

- Eliminar resoluciones < 480px para aplicaciones de seguridad.
- El umbral de confianza queda acotado a un rango de 0.45-0.55.

4.3 Configuración Óptima para Producción

```
model = YOLO('yolo11n-pose.pt')
results = model.predict(
    source='webcam',
    imgsz=640,      # Punto de saturación óptimo
    conf=0.50,      # Balance sensibilidad-especificidad
    verbose=False
)
```

5. Inspección Visual de Poses (Keypoints)

Para la inspección visual de poses, se presenta una muestra de imágenes del dataset con los *keypoints* detectados por el modelo YOLO11n-pose. Este procedimiento permite realizar una evaluación cualitativa de la precisión en la estimación de pose, la cual funciona como complemento directo al análisis cuantitativo previo. Para esta ejecución, se aplicó la configuración óptima identificada durante los experimentos, estableciendo la resolución de entrada en 640px y el umbral de confianza en 0.50.

El análisis cualitativo de la salida directa del modelo permite observar y validar tres aspectos operativos críticos. En primer lugar, se evalúa la precisión anatómica de los *keypoints*, verificando que la superposición del esqueleto virtual coincida exactamente con las articulaciones reales de los sujetos (hombros, codos, muñecas), manteniendo esta exactitud incluso en escenarios con baja iluminación. En segundo lugar, se comprueba la robustez geométrica; por ejemplo, en la secuencia de asalto, se requiere que el modelo no pierda el seguimiento espacial y logre estructurar la pose a pesar de la disposición atípica que representa el gesto de "manos arriba".

Finalmente, la revisión facilita un control estricto sobre las detecciones erróneas, permitiendo identificar visualmente si el algoritmo proyecta esqueletos sobre elementos inanimados (falsos positivos) o si fracasa al registrar a un individuo presente en el encuadre (falsos negativos). Este nivel de examen visual constituye un paso indispensable frente a la validación puramente estadística, asegurando la verdadera aplicabilidad del modelo en un entorno de videovigilancia real.

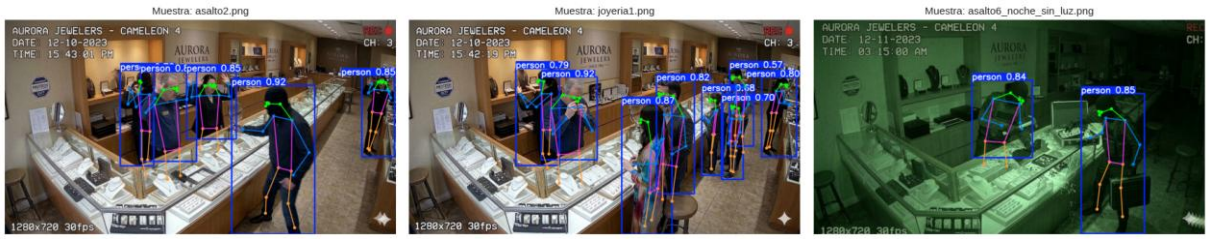

6. Inspección Visual Completa del Dataset (13 imágenes)

A continuación, se muestran todas las imágenes del dataset con los keypoints detectados por YOLO11n-pose. Esto permite una evaluación cualitativa exhaustiva de la precisión de la estimación de pose en cada escenario.

Configuración utilizada: Resolución 640px | Umbral de Confianza 0.50

Figura 5. Inspección Visual de Keypoints - Dataset Completo (13 imágenes)

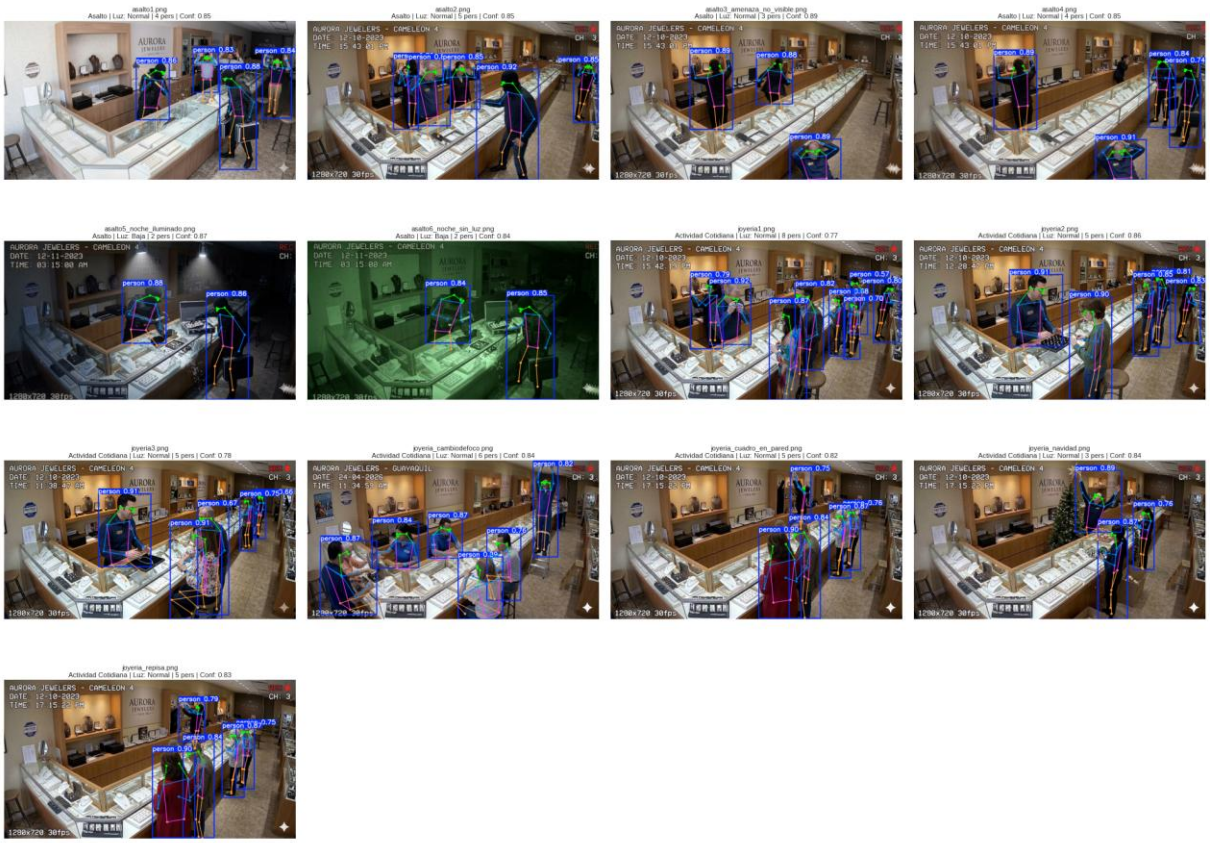

7. Capa Lógica: Detección de "Manos Arriba" por Triangulación

Siguiendo el criterio geométrico definido en nuestro marco teórico (Cao et al., 2019), se implementó una capa de decisión heurística encargada de interpretar las detecciones del modelo. Esta capa aísla tres *keypoints* anatómicos de interés por cada persona detectada, basándose en la nomenclatura estándar del dataset COCO: la nariz (índice 0), la muñeca izquierda (índice 9) y la muñeca derecha (índice 10).

A partir de la extracción de estos puntos, el sistema evalúa la condición geométrica de la pose. Si ambas muñecas se encuentran espacialmente por encima de la nariz, se activa automáticamente el indicador de alerta clasificado como "MANOS ARRIBA". Para facilitar la auditoría del sistema, se genera una visualización que dibuja un triángulo conectando los tres puntos clave, aplicando el siguiente código de colores según el estado detectado:

- **Triángulo ROJO:** Muñecas por encima de la nariz → MANOS ARRIBA (ALERTA).
- **Triángulo VERDE:** Muñecas por debajo de la nariz → MANOS ABAJO (NORMAL).

Tabla 1 Índices de Keypoints COCO relevantes

Índice	**Keypoint**
0	Nariz
9	Muñeca Izquierda
10	Muñeca Derecha

Tabla 2 Resultados consolidados de la Capa Lógica

Estado Detectado	**Conteo**
MANOS ARRIBA	9
MANOS ABAJO	40
No detectado	0

Figura 6. Capa Lógica: Detección de "Manos Arriba" por Triangulación Nariz-Muñecas

Los datos procesados demuestran que la capa lógica implementa exitosamente el criterio geométrico diseñado: exigir que ambas muñecas superen el eje Y de la nariz para disparar el estado de alerta. Esta validación visual permite verificar empíricamente que el sistema no se limita a la simple detección de *keypoints*, sino que logra interpretar de manera correcta la intención del gesto, cumpliendo así con el objetivo final del proyecto de videovigilancia.

8. Anexos

Todas las imágenes procesadas han sido almacenadas en Google drive para su revisión.

https://drive.google.com/drive/folders/10WX7KGn2iEY1GYwolYHbrsqQPu1hqHBo?usp=sharing

Todo el código usado se encuentra en nuestro repositorio de GitHub en la ruta javier_mario\GRUPO_5\codigo:

https://github.com/pataconforce/Egida

9. Referencias

Cao, Z., Hidalgo, G., Simon, T., Wei, S. E., & Sheikh, Y. (2019). OpenPose: Realtime Multi-Person 2D Pose Estimation using Part Affinity Fields. IEEE Transactions on Pattern Analysis and Machine Intelligence, 43(1), 172–186. https://ieeexplore.ieee.org/abstract/document/8765346

Jocher, G., Qiu, J., & Zhong, Z. (2024). Ultralytics YOLO11: Real-time Object Detection and Pose Estimation. Ultralytics. https://docs.ultralytics.com/

Lin, T. Y., Maire, M., Belongie, S., Hays, J., Perona, P., Ramanan, D., Dollar, P., & Zitnick, C. L. (2014). Microsoft COCO: Common objects in context. En Computer Vision – ECCV 2014 (pp. 740–755). Springer. https://doi.org/10.1007/978-3-319-10602-1_48

Wang, L., Wang, H., Letchmunan, S., Xiao, R., Ahmed, O. H., & Liu, Z. (2025). A systematic literature review of lightweight YOLO models for object detection. *PeerJ Computer Science, 11*, e3357. https://peerj.com/articles/cs-3357/