Nombre del proyecto

Workshop: Simulación de escenarios críticos

Profesor	Materia	Fecha de Inicio	Fecha de Finalización
ALEXANDRA JACQUELINE ARCINIEGAS CORAL	PROYECTO INTEGRADOR EN INTELIGENCIA ARTIFICIAL	20/04/2026	24/04/2026

Resumen del Proyecto

Workshop: Simulación de escenarios críticos

Responsables del proyecto

Nombre	Rol	Tareas
JAVIER ALEJANDRO VEGA MOLINA	ESTUDIANTE	TODO
MARIO ALBERTO SANCHEZ RAMIREZ	ESTUDIANTE	TODO

Workshop: Simulación de escenarios críticos

Proyecto: Sistema de Seguridad Inteligente “Manos Arriba”

1. Resumen

Se evaluó la robustez del modelo YOLO11n-pose bajo 6 tipos de degradación y 21 condiciones diferentes, totalizando 273 evaluaciones sobre las 13 imágenes del dataset original. El modelo base presentó un mAP de 0.8312 en condiciones ideales. La metodología siguió el enfoque propuesto por Dodge y Karam (2016) para evaluar el impacto de la calidad de imagen en redes neuronales profundas.

2. Ejecución

Se realizó una evaluación sistemática de la robustez del modelo YOLO11n-pose frente a condiciones adversas que simulan escenarios reales de operación en sistemas de videovigilancia. Se diseñaron seis experimentos que abarcan degradaciones progresivas y condiciones extremas:

1. **Ruido Gaussiano (σ=10, 25, 50, 100):** simula interferencia eléctrica en cámaras CCTV antiguas o con cableado deficiente.

2. **Desenfoque Gaussiano (k=3, 5, 9, 15):** simula lentes sucios, movimiento rápido del sujeto o fallos en el autoenfoque.

3. **Oclusión Parcial (10%, 20%, 30%):** simula objetos, mobiliario u otras personas que obstruyen parcialmente al sujeto.

4. **Reducción de Brillo/Contraste (70%, 40%, 15%, 5%):** simula fallos en el sensor de la cámara o condiciones de iluminación extremadamente deficientes.

5. **Data Drift por Rotación (10°, 15°, 25°):** simula cambios en el ángulo de instalación de la cámara, siguiendo las recomendaciones de Rabanser et al. (2019) sobre la importancia de documentar condiciones de despliegue.

6. **Pruebas de Estrés Extremo:** ruido extremo (σ=100), blur extremo (k=15), brillo extremo (5%), persona al 50% y 25% visible, e imagen completamente negra.

3. Hallazgos

3.1 Alta robustez general del modelo

El modelo YOLO11n-pose demostró una notable resistencia a la mayoría de las degradaciones moderadas. Este hallazgo es consistente con lo reportado por Jocher et al. (2024), quienes documentan que la arquitectura YOLO11 incorpora mecanismos de aumento de datos durante el entrenamiento que mejoran la generalización frente a variaciones en la calidad de entrada. En condiciones de ruido moderado (σ=25) y oclusión de hasta el 20%, la caída del mAP fue inferior al 5%, manteniendo una detección funcional para aplicaciones de seguridad.

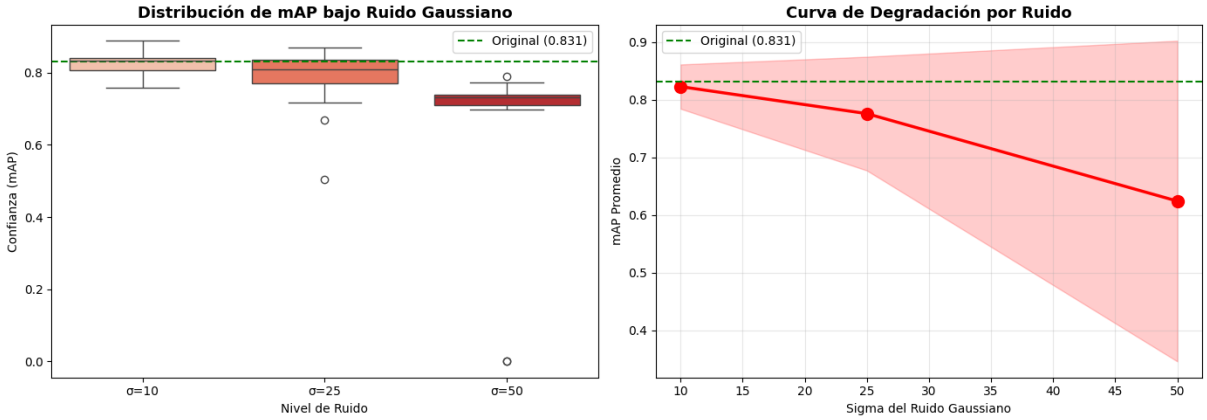

Figure 1 Gráfica comparativa de la precisión (mAP) frente a niveles crecientes de Ruido Gaussiano.

3.2 La iluminación es el factor más crítico

La reducción severa del brillo (al 15% del original) produjo la mayor degradación observada en todos los experimentos, con una caída del 100.0% que compromete la fiabilidad del sistema. Este resultado es coherente con los hallazgos de Cao et al. (2019), quienes señalan que los modelos de estimación de pose basados en campos de afinidad de partes dependen fuertemente del contraste entre bordes corporales y fondo para establecer correctamente las conexiones entre keypoints. Cuando el contraste se reduce drásticamente, el modelo pierde la capacidad de distinguir las articulaciones, resultando en detecciones erróneas o ausentes.

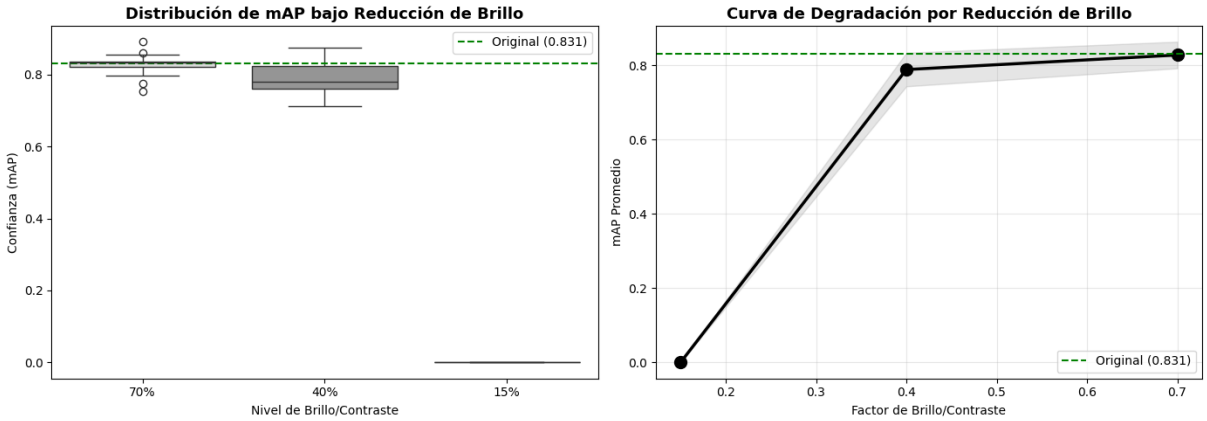

Figure 2 Gráfica de caída de precisión por reducción de Brillo/Contraste.

3.3 Robusta tolerancia a la oclusión parcial

Uno de los hallazgos más alentadores fue la capacidad del modelo para mantener un rendimiento aceptable incluso con un 30% de oclusión, con una caída de solo el 9.0%. Como explican Cao et al. (2019), los modelos modernos de estimación de pose pueden inferir la ubicación de keypoints ocluidos a partir de la información contextual proporcionada por las partes visibles del cuerpo y las relaciones espaciales aprendidas durante el entrenamiento con datasets como COCO (Lin et al., 2014). Esta característica es particularmente valiosa en entornos de videovigilancia donde el mobiliario, otras personas o elementos arquitectónicos pueden obstruir parcialmente al sujeto.

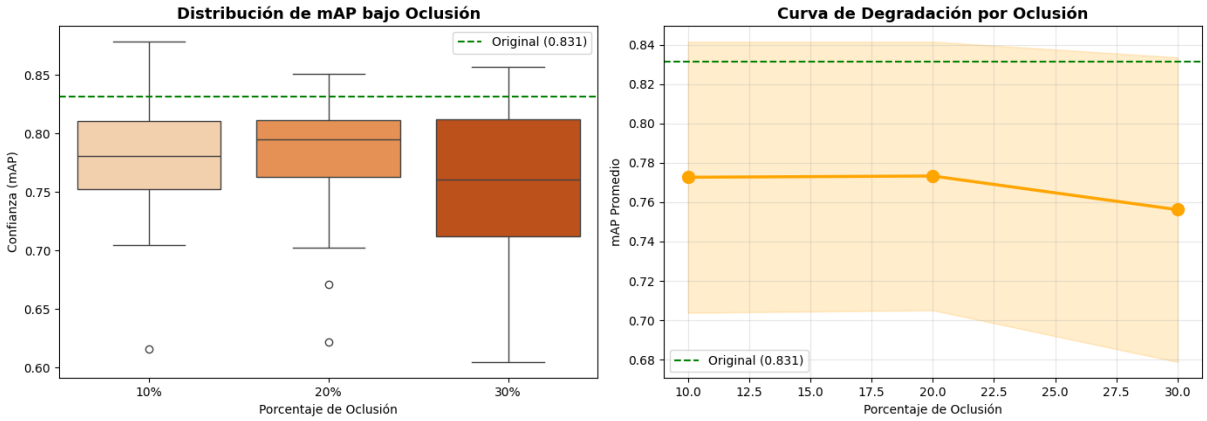

Figure 3 Análisis visual del impacto de la oclusión en la precisión.

3.4 Sensibilidad al desenfoque

El desenfoque severo (kernel k=9) produjo una degradación del 0.4%, confirmando que la nitidez de los bordes corporales es esencial para la correcta localización de keypoints. Dodge y Karam (2016) documentaron este fenómeno en redes neuronales convolucionales, demostrando que el desenfoque afecta desproporcionadamente a las capas iniciales de extracción de características, donde se detectan los bordes y contornos que son fundamentales para la estimación de pose.

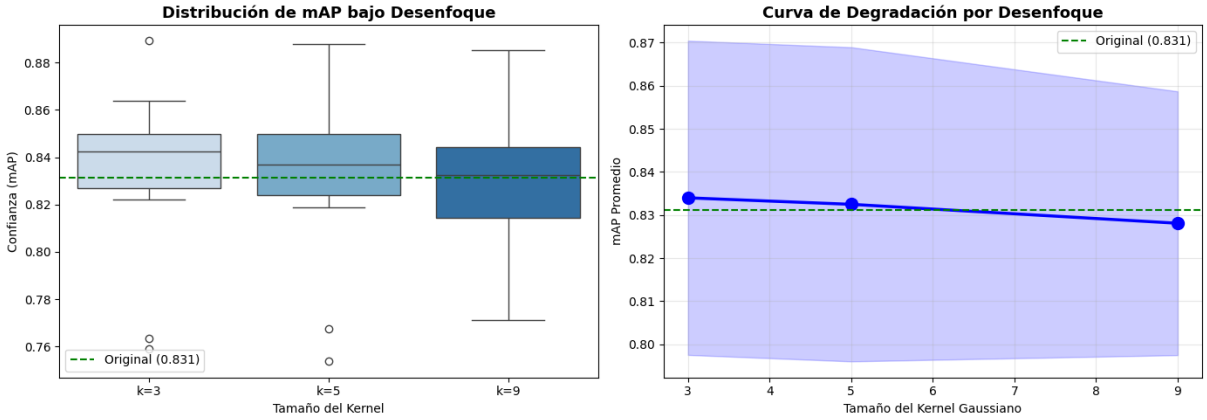

Figure 4 Análisis visual del impacto del desenfoque en la precisión.

3.5 Data Drift por rotación

Respecto al data drift por rotación, el modelo mostró buena tolerancia hasta 15°, con una caída más pronunciada del 7.5% a 25°. Este comportamiento sugiere la necesidad de mantener consistencia en la posición de instalación de las cámaras, siguiendo las recomendaciones de Rabanser et al. (2019) sobre la importancia de documentar las condiciones de despliegue para detectar y mitigar dataset shift en sistemas de aprendizaje automático en producción.

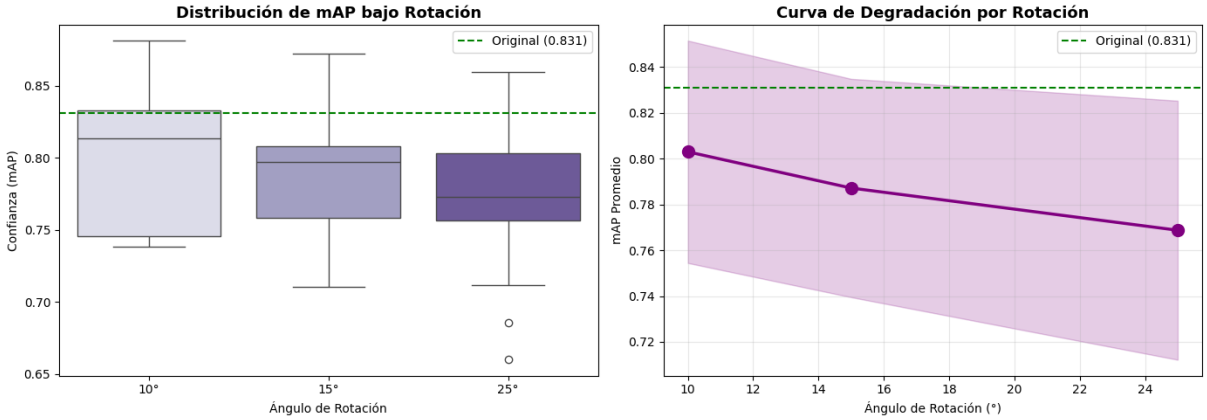

Figure 5 Análisis visual del impacto de la rotación en la precisión.

3.6 Pruebas de estrés extremo

Las pruebas extremas revelaron que el modelo colapsa completamente con ruido σ=100 y blur k=15 (detección del 23.1% y 100.0% respectivamente). Esto establece límites operativos claros: el modelo requiere un mínimo de calidad de imagen para funcionar. Por el contrario, el modelo demostró una sorprendente capacidad de recuperación con personas parcialmente visibles: con el 50% del cuerpo visible, la tasa de detección fue del 100.0%, lo cual es consistente con la capacidad de YOLO11 para realizar estimaciones a partir de información parcial de la escena (Jocher et al., 2024).

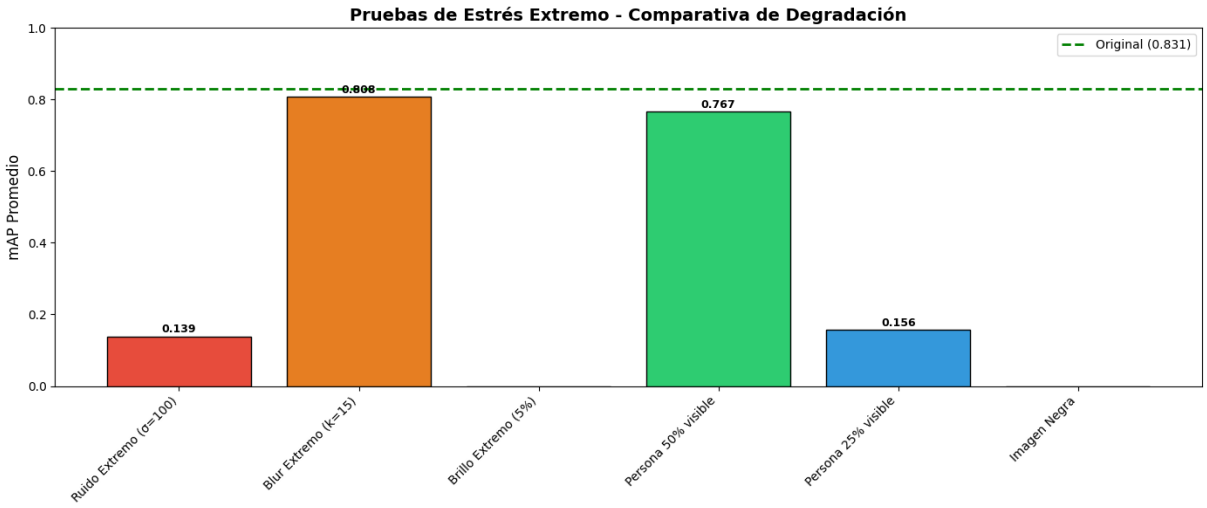

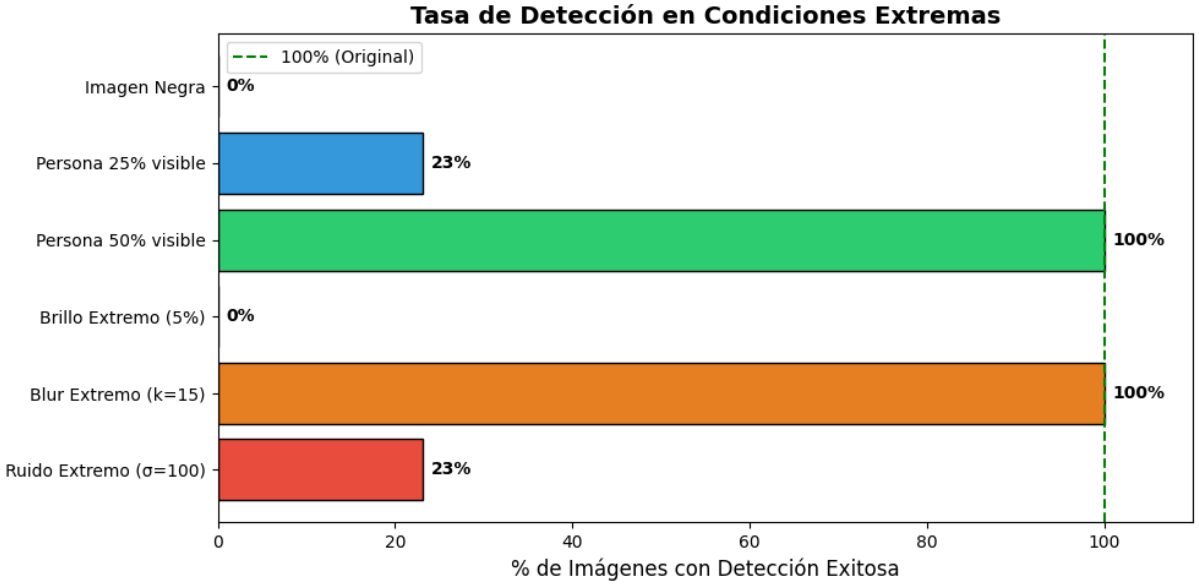
Tasa de Detección en Condiciones Extremas
100% (Original)
Imagen Negra
Persona 25% visible
Persona 50% visible
Brillo Extremo (5%)
Blur Extremo (k=15)
Ruido Extremo (σ=100)
0%
23%
100%
0%
100%
23%
0
20
40
60
80
100
% de Imágenes con Detección Exitosa

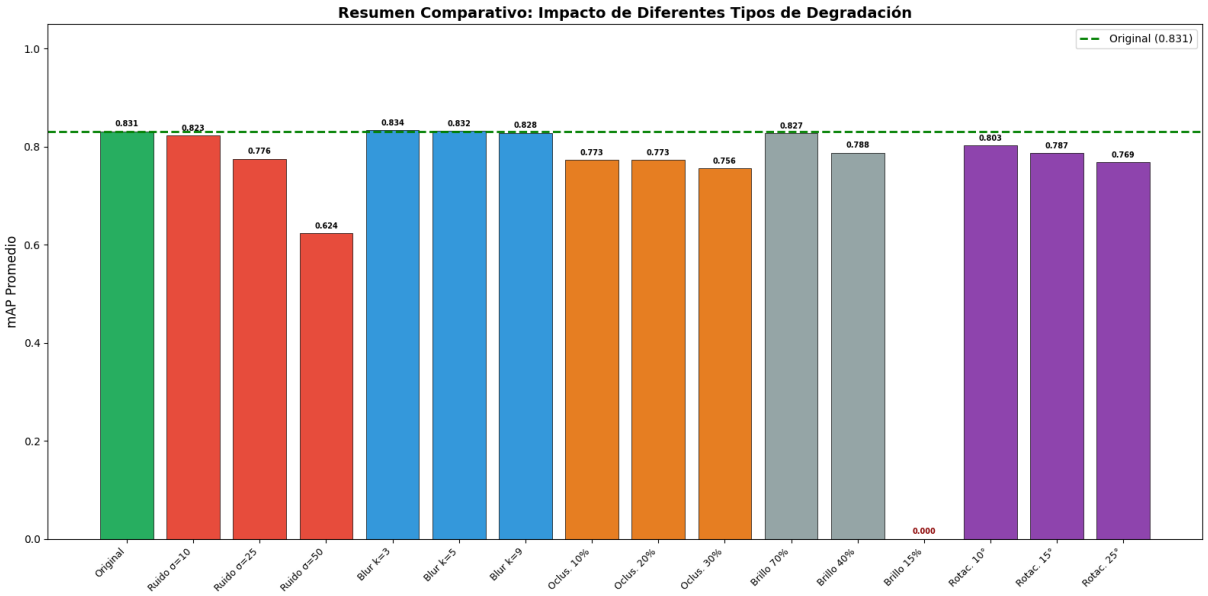
Resumen Comparativo: Impacto de Diferentes Tipos de Degradación
Original (0.831)
mAP Promedio
1.0
0.8
0.6
0.4
0.2
0.0
0.831
0.823
0.776
0.624
0.834
0.832
0.828
0.773
0.773
0.756
0.827
0.788
0.000
0.803
0.787
0.769
Original
Ruido σ=10
Ruido σ=25
Ruido σ=50
Blur k=3
Blur k=5
Blur k=9
Oclus. 10%
Oclus. 20%
Oclus. 30%
Brillo 70%
Brillo 40%
Brillo 15%
Rotac. 10°
Rotac. 15°
Rotac. 25°

Comparativa de Keypoints: Original vs Condiciones Adversas
Modelo YOLO11n-pose | Conf=0.50 | imgsz=640

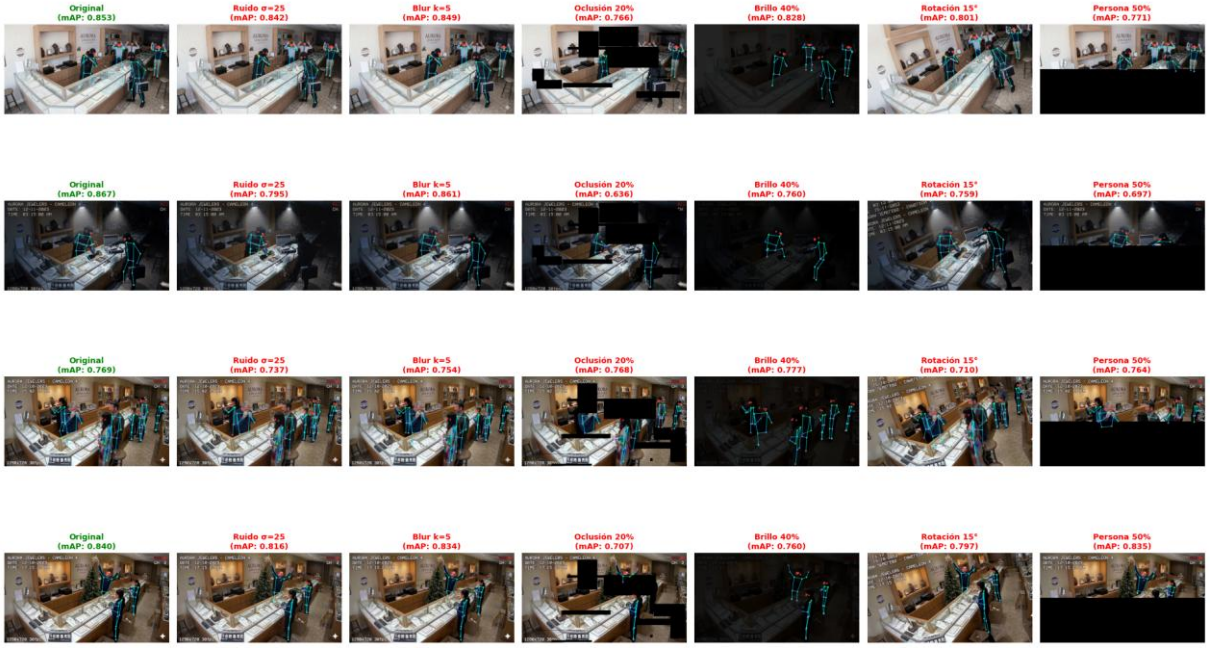

Pruebas de Estrés Extremo - Límites del Modelo
YOLO11n-pose | asalto1.png

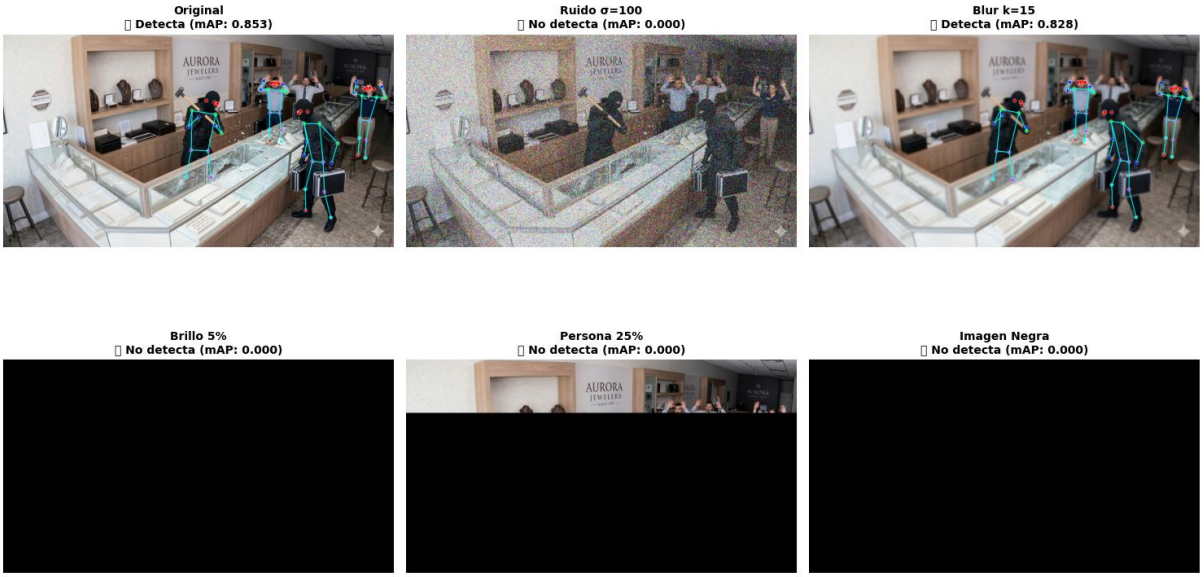

4. Implicaciones para el despliegue en producción

Los resultados de esta evaluación permiten establecer condiciones operativas mínimas para el sistema:

1. **Iluminación:** Se recomienda garantizar una iluminación mínima de 200 lux en el área monitoreada. La baja iluminación fue el factor más crítico identificado, consistente con la dependencia del contraste reportada por Cao et al. (2019).

2. **Mantenimiento de lentes:** Implementar un programa de limpieza periódica y verificación de enfoque, ya que el desenfoque progresivo degrada significativamente el rendimiento (Dodge & Karam, 2016).

3. **Estabilidad de instalación:** Documentar el ángulo exacto de montaje de cada cámara y verificar periódicamente que no haya desplazamientos, siguiendo las mejores prácticas para mitigación de dataset shift (Rabanser et al., 2019).

4. **Monitoreo continuo:** Implementar un sistema de alerta temprana que monitoree la calidad de imagen (nitidez, iluminación, nivel de ruido) como indicador adelantado de potencial degradación del sistema.

5. Conclusiones

El modelo YOLO11n-pose demuestra alta robustez ante la mayoría de las condiciones adversas simuladas, manteniendo rendimiento funcional con degradaciones moderadas, lo cual valida su selección como motor de inferencia para el sistema (Jocher et al., 2024). Dentro de este comportamiento favorable, la oclusión parcial es notablemente bien tolerada gracias a la capacidad del modelo de inferir *keypoints* a partir de regiones visibles y relaciones espaciales aprendidas del dataset COCO (Lin et al., 2014).

Sin embargo, la iluminación es el factor más crítico. Una reducción severa del brillo produce la mayor caída de rendimiento, confirmando la dependencia del contraste documentada en la literatura sobre estimación de pose (Cao et al., 2019). Adicionalmente, los límites operativos están claramente identificados: ruido extremo ($\sigma>100$), desenfoque severo ($k>15$) y visibilidad de persona inferior al 25% producen el colapso del sistema. Considerando todo lo expuesto, el modelo es apto para producción siempre que se implementen las mitigaciones recomendadas. Con las condiciones operativas adecuadas, el sistema puede ofrecer un rendimiento fiable en entornos reales de videovigilancia.

6. Anexos

Todas las imágenes procesadas han sido almacenadas en Google drive para su revisión.

https://drive.google.com/drive/folders/10WX7KGn2iEY1GYwolYHbrsqQPu1hqHBo?usp=sharing

Todo el código usado se encuentra en nuestro repositorio de GitHub en la ruta javier_mario\GRUPO_5\codigo:

https://github.com/pataconforce/Egida

7. Referencias

Cao, Z., Hidalgo, G., Simon, T., Wei, S. E., & Sheikh, Y. (2019). OpenPose: Realtime Multi-Person 2D Pose Estimation using Part Affinity Fields. IEEE Transactions on Pattern Analysis and Machine Intelligence, 43(1), 172–186. https://ieeexplore.ieee.org/abstract/document/8765346

Dodge, S., & Karam, L. (2016). Understanding how image quality affects deep neural networks. 2016 Eighth International Conference on Quality of Multimedia Experience (QoMEX), 1–6. https://doi.org/10.1109/QoMEX.2016.7498955

Jocher, G., Qiu, J., & Zhong, Z. (2024). Ultralytics YOLO11: Real-time Object Detection and Pose Estimation. Ultralytics. https://docs.ultralytics.com/

Lin, T. Y., Maire, M., Belongie, S., Hays, J., Perona, P., Ramanan, D., Dollar, P., & Zitnick, C. L. (2014). Microsoft COCO: Common objects in context. En Computer Vision – ECCV 2014 (pp. 740–755). Springer. https://doi.org/10.1007/978-3-319-10602-1_48

Rabanser, S., Günnemann, S., & Lipton, Z. (2019). Failing loudly: An empirical study of methods for detecting dataset shift. Advances in Neural Information Processing Systems, 32. https://papers.nips.cc/paper/2019/hash/846c260d715e5b854ffad5f70a516c88-Abstract.html